

保證收入預測系統

技術複習手冊

RMSE、MAE、MAPE、模型參數、特徵工程、Walk-forward、Hybrid、資料洩漏與模型治理

用途	個人複習、技術交接、模型審查與面試準備
範圍	Warranty Revenue Forecasting System V2.2 與 Feature Selection Lab
版本	2026-07 技術基準版
資料原則	僅使用合成示例，不收錄公司實際敏感數值

從「模型跑得出來」到「證明模型可信」

導讀 這份手冊要解決什麼？

這不是一份 R 語法教學，而是一張完整的判讀地圖：看到模型輸出時，知道每個數字代表什麼、何時能相信、何時應該懷疑，以及它在整個保證收入預測流程中的位置。

核心結論

預測品質不能只看單一 RMSE。可上線的結果至少要同時通過：資料可取得性、無洩漏、公平回測、足夠樣本、跨據點穩定性、預測區間與失敗時的 fallback。

閱讀順序

章	主題	你要帶走的能力
01	系統全貌	先理解 ARIMA、ETS、XGB、Hybrid 與基準模型的分工
02	誤差指標	RMSE、MAE、MAPE、WAPE、Bias、n 與排名
03	XGBoost 參數	學習率、樹深、抽樣、正則化、rounds 與 early stopping
04	特徵工程	Lag、Rolling、Trend、Growth、Volatility、季節與日 / 週摘要
05	時序驗證	Walk-forward、h=1~6、Recursive、Common-key 與 Nested
06	資料洩漏	Target、Temporal、Availability、Selection leakage
07	Hybrid 與區間	權重、誤差相關性、回測殘差與 fallback
08	特徵選擇	RFE、Ablation、Bootstrap、Champion / Challenger
09	正式路由	不同據點與 horizon 的 Feature Router，以及 A56
10	實務判讀	輸出物件閱讀順序、常見誤解與快速檢查表

技術摘要：目前系統採月資料、據點層級、1~6 個月多期預測；比較簡單基準、ARIMA、ETS 與遞迴式 XGBoost，再以逆 RMSE 權重形成 Hybrid。正式 V2.2 已加入 horizon-aware 特徵路由、A53 guardrail 與 A56 小樣本 fallback。

01 系統全貌

每個模型回答不同問題；Hybrid 不是第四種演算法，而是組合策略。

模型 / 基準	核心概念	擅長	主要風險
Seasonal Naive	沿用去年同月	強季節性、快速基準	遇到結構性成長或制度改變會落後
Rolling3 / 6	近期 3 / 6 月平均	平滑短期噪音	對突然轉折反應慢
ARIMA	利用自相關、差分與殘差結構	線性時間依賴	非線性及外生訊號有限
ETS	誤差、趨勢、季節的指數平滑	平滑趨勢與季節型態	對不規則尖峰較弱
XGB	樹模型逐輪修正殘差	非線性與特徵交互作用	易受洩漏、樣本少與遞迴誤差影響
Hybrid	按歷史誤差加權多模型	分散單一模型失誤	權重若不獨立評估，結果可能樂觀

系統資料流

歷史月資料	→	合法特徵	→	Walk-forward 回測	→	模型比較
完整月份	→	h-aware 路由	→	ARIMA / ETS / XGB	→	Hybrid + 區間

簡單模型贏，不代表專案失敗

ETS 或 ARIMA 在某些據點 / horizon 勝出，表示該區段的訊號較規律。真正成熟的系統會讓證據決定模型，而不是強迫最複雜的模型獲勝。

02 誤差指標與意義

Actual 是實際值，Pred 是預測值， $e = \text{Pred} - \text{Actual}$ 。

指標	公式	單位	回答的問題	主要陷阱
RMSE	$\sqrt{\text{mean}((\text{Pred} - \text{Actual})^2)}$	與收入同單位	放大大誤差；適合懲罰爆掉的月份	受極端值影響大
MAE	$\text{mean}(\text{Pred} - \text{Actual})$	與收入同單位	典型月份平均差多少；直觀	不特別懲罰極端誤差
MAPE	$\text{mean}(\text{Pred} - \text{Actual} / \text{Actual}) \times 100\%$	%	跨據點看相對誤差	Actual 接近 0 時失真
WAPE	$\Sigma \text{Pred} - \text{Actual} / \Sigma \text{Actual} \times 100\%$	%	用總量加權，較不受單筆低值扭曲	大額月份主導結果
Bias	$\text{mean}(\text{Pred} - \text{Actual})$	與收入同單位	正值偏高估、負值偏低估	正負誤差會互相抵銷
n	有效回測筆數	筆	判斷證據量	n 小時排名非常不穩
RMSE rank	同據點同 h 依 RMSE 排名	名次	快速找 winner	看不到差距大小與不確定性

合成範例

項目	結果
實際	100, 120, 80
預測	90, 130, 100
RMSE	14.14
MAE	13.33
MAPE	14.44%
Bias	6.67 (整體偏高估)

怎麼一起讀？

RMSE 明顯高於 MAE，通常表示少數月份誤差特別大；MAPE 高但 MAE 不高，可能是 Actual 偏低；Bias 接近 0 不代表準確，因為高估與低估可能剛好抵銷。

本專案的判讀優先順序

- 第一層：先確認無洩漏、時間切分正確、模型使用相同 common samples。
- 第二層：以 RMSE 作主要 ranking，MAE 檢查典型誤差，MAPE / WAPE 補充相對尺度。
- 第三層：檢查 Bias、n、各據點與各 h 是否一致，而不是只看全體平均。
- 第四層：用 bootstrap 或外層測試確認改善不是抽樣運氣。

03 XGBoost 參數字典

參數控制學習速度、樹的複雜度、隨機性與過度擬合。

參數	目前基準	控制什麼	解讀 / 風險
objective	reg:squarederror	學習目標為平方誤差回歸	通常不需調
eval_metric	rmse	用 RMSE 監控訓練 / 驗證表現	必須與決策指標一致
eta	0.05	每棵樹修正幅度；越小越保守	小 eta 通常需要更多 rounds
max_depth	4	單棵樹最大深度；控制交互作用複雜度	太深易記住噪音
min_child_weight	3	葉節點成立所需的最小權重	越大越保守
subsample	0.8	每輪抽取 80% 訓練列	降低變異；太低會欠擬合
colsample_bytree	0.8	每棵樹抽取 80% 特徵	降低特徵共線與過擬合
lambda	預設 / 候選	L2 正則化，讓權重更平滑	大值更保守
alpha	預設 / 候選	L1 正則化，鼓勵稀疏權重	可能壓掉弱訊號
nrounds	正式版 200	Boosting 樹的最大輪數	不是越多越好
early_stopping_rounds	實驗版 30	驗證 RMSE 多輪未改善就停止	驗證集必須位於未來
seed	20260717	固定抽樣隨機性以利重現	不能消除資料不確定性

訓練輸出怎麼看？

- **train-rmse 持續下降、test-rmse 上升**：典型過度擬合。
- **train 與 test 都高**：特徵不足、參數太保守，或訊號本身有限。
- **最佳 iteration 很早**：模型很快碰到泛化極限；再加 rounds 沒有幫助。
- **最佳 iteration 很晚**：不必然代表更好，仍要用 walk-forward 外層資料驗證。

目前正式設定的意義

V2.2 使用 Top / Safe 特徵路由，但保留原固定 XGB 參數與 200 rounds。先前調參實驗曾受到洩漏特徵影響，因此不能把當時的最佳參數直接升級到正式模型。

Feature Importance

欄位	意義	如何使用
Gain	某特徵帶來的平均損失下降	主要參考；高 Gain 代表模型常靠它降低誤差
Cover	使用該特徵的節點涵蓋多少樣本	看影響範圍，不等於預測增益
Frequency	被用於分裂的頻率	常出現不代表重要；可能只是容易被切分

注意：重要性不是因果關係，也不是自動的特徵保留名單。若特徵在預測當下不可取得，Gain 再高也不能上線。

04 特徵工程字典

特徵的價值取決於「訊號」與「預測時可取得性」兩件事。

群組	例子	想捕捉的訊號	風險
Calendar	month、quarter、year	時間位置與長期漂移	year 可能只是代理趨勢
Season cyclic	sin_month、cos_month	把 12 月與 1 月視為相鄰	有季節性不代表一定改善
Lag	lag1 / 2 / 3_申請總金額	近期延續性	h 增加時可能需遞迴值
External lag	lag1 / 2 / 3_310、412、對策、保證件數	業務活動的領先訊號	非目標欄位必須真的已知
Rolling	rolling3 / 6	近期水準與平滑	不可混入預測月份
Trend	trend_3m / 6m	近期斜率	短窗易受尖峰扭曲
Growth	growth_1m / 3m	動能與轉折	分母小時不穩定
Volatility	volatility_3m / 6m	近期不確定性 / regime	可能較適合預測誤差而非點預測
YoY	lag12 或安全的去年同期值	年度季節基準	同月 growth 可能直接洩漏答案
Daily activity	日收入 SD / CV、active days、zero-day ratio	月內分布與作業密度	聚合方式必須只用已完成月份
Concentration	max-day share、top3 share	收入是否集中少數日期	極端日可能主導
Frequency domain	spectral entropy、weekly power share	規律性與頻率結構	短序列下估計不穩
Weekly shape	weekly CV / slope	月內週節奏	月長與跨月週切割需一致

Volatility、Entropy 與季節特徵為什麼沒穩定上榜？

它們可能描述資料結構，卻不一定能降低下一期點預測誤差。另一種可能是訊號已被 lag / rolling 吸收，或樣本量不足以穩定估計。這正是要用 ablation 與外層回測回答，而不能只看一次 Gain。

V3 的結論

日 / 週摘要的 Activity 群組曾出現點估計改善，但 bootstrap 證據不足；其他 V3 群組與完整 V3 多數惡化。因此 V3 Activity 目前是 h=1 Challenger，不是正式 Feature Router 的預設。

05 時序驗證：模型可信度的核心

時間序列不能像一般表格資料隨機打散。

方法	做法	價值	限制
Holdout	早期訓練、後期測試	快速檢查	對單一期間過度敏感
Walk-forward	每次只用當時以前資料，預測下一期	模擬真實上線	計算量較大
Expanding window	訓練窗隨時間累積	保留全部歷史	制度改變後舊資料可能拖累
horizon h	h=1~6 代表提前 1~6 月	區分近 / 中期難度	不同 h 的合法特徵不同
Recursive	先預測 h=1，再把預測寫回特徵推 h=2	可產生多期 XGB	誤差逐期累積
Common-key	模型只在共同的據點 / 年月 / h 評估	公平比較	樣本可能減少
Nested selection	外層測試；內層選特徵 / 參數	避免選擇洩漏	最耗計算但最可信

h=1 ~ 6 的直覺

Horizon	時間意義	建模含義
h=1	下一個月	近期 lag / 活動摘要通常最有用
h=2~4	中短期	可取得特徵減少，遞迴值開始影響
h=5~6	較遠期	安全的長期 / YoY / 日曆特徵更重要，誤差通常較不穩

Common-key 完整性條件

- 每個據點 × 年月 × h 應有 ARIMA、ETS、XGB 三個模型。
- 同一 key 的 Actual 必須唯一，Pred 與權重不可缺失。
- 同一模型不可在同一 key 重複出現。
- 比較 RMSE 時，各模型必須使用完全相同的 key；否則名次可能只是樣本不同。

那次 Hybrid error 的真正價值

檢查抓到某些回測資料每個 key 只有一個模型，並不是「很外行的 Error」。它揭露的是資料結構與評估設計不一致；若沒有停止，Hybrid 會看似成功但其實缺模型。

06 資料洩漏與可取得性

模型看見未來，回測就會漂亮得不真實。

類型	定義	例子	防治
Target leakage	特徵直接或間接包含 Actual	當月 YoY growth 可由去年值反推當月收入	移除或改用 lag12 安全值
Temporal leakage	計算特徵時用了測試期以後資料	全資料先做 rolling / 標準化再切分	每個 fold 內重算
Availability leakage	歷史上有欄位，但預測當下尚未知	h=3 卻使用未來第 1~2 月案件數	建立 h-aware availability 規則
Selection leakage	用完整測試期挑特徵或參數	先看所有月份 Gain，再宣稱回測	Nested walk-forward

本專案的可取得性規則

特徵類型	規則	原因
同月 growth 類	不可用	當月資訊尚未完整，且可能藏有目標答案
非目標 lag k	僅當 $k \leq h$ 才可用	例如 h=3 時，lag1 / lag2 是未知未來
非目標 rolling	原則上只在 h=1 使用	多期時會混入尚未發生的活動
YoY lag12	h=1~6 可用	所需月份仍位於已知歷史
目標 lag / rolling / trend	可遞迴使用	以先前預測更新，但要承擔累積誤差

未完整月份

正式建模資料必須排除當月末結束的部分月：年月 < floor_date(Sys.Date(), "month")。否則收入與活動量都會被誤認為異常低值，並污染 lag、rolling 與回測。

預測前五問

- 這個欄位在預測產生當天真的已經知道嗎？
- 它是否含有本月完整結果、結帳後才產生的資訊或 Actual 的變形？
- 它的 rolling / scaling / encoding 是否只用當時以前資料計算？
- 在 h=6 時仍然合法嗎？還是只適用 h=1？
- 特徵是因外層回測穩定勝出，還是只因完整資料上的一次重要性很高？

07 Hybrid 權重與預測區間

組合模型的重點不是加權公式，而是權重與誤差是否被公平估計。

逆 RMSE 權重

$$\text{inv_rmse}_m = 1 / \text{RMSE}_m \quad \text{weight}_m = \text{inv_rmse}_m / \sum \text{inv_rmse}_m \quad \text{Hybrid Pred} = \sum \text{weight}_m \times \text{Pred}_m$$

RMSE 較低的模型獲得較高權重，但三個模型都保留。正式流程先嘗試據點 $\times$ h 權重；若該 horizon 樣本不足或模型不完整，退回據點層級權重，再重新正規化使總和等於 1。

權重 / 來源	粒度	優點	風險
Branch weight	據點 $\times$ model	樣本較多、穩定	忽略不同 h 的難度
Horizon weight	據點 $\times$ h $\times$ model	能反映近 / 遠期差異	小樣本容易過擬合
weight_h	完整且合法時優先	較細緻	需 common-key 驗證
branch_fallback	h 權重不足時使用	不中斷正式輸出	個別 h 未客製化

Hybrid 95% 區間

$$\text{lower95} = \max(0, \text{Pred} - 1.96 \times \text{Hybrid RMSE})$$

$$\text{upper95} = \text{Pred} + 1.96 \times \text{Hybrid RMSE}$$

目前的 Hybrid RMSE 由歷史 Hybrid 回測殘差直接估計，因而自然保留 ARIMA、ETS、XGB 誤差之間的相關性；這比把三個 RMSE 平方後加權的簡化近似更合理。A56 若無足夠的據點 $\times$ h 殘差，使用據點層級 fallback。

區間不是保證

$1.96 \times \text{RMSE}$ 是常態近似尺度，不等於已完成嚴格 calibration。若殘差偏態、重尾、樣本少或 regime 改變，實際 95% 覆蓋率可能不足；應另外追蹤 coverage 與 interval width。

仍需治理的重點

- 權重若在同一批回測樣本上估計又在同批樣本上評分，Hybrid 表現可能偏樂觀。
- 理想做法是在每個外層月份，只用更早的殘差計算當期權重。
- 若某模型缺失，不可用 `na.rm = TRUE` 靜默忽略；必須停止或明確 fallback。
- 需保存 `weight_source`、模型數量、權重和與誤差樣本數，才能追溯每筆預測。

08 特徵選擇與證據強度

目標不是找到最炫的特徵，而是找到在未來仍穩定有效的最小集合。

方法	怎麼做	回答什麼
Audit	缺失、型別、近零變異、高相關、洩漏名稱	先排除明顯資料問題
Time-series RFE	每個訓練窗內依重要性建立不同大小子集	避免用未來挑特徵
Stability selection	統計跨窗入選率與排名波動	區分核心、條件與噪音特徵
Ablation	一次加入 / 移除一個特徵群組	隔離 Volatility、季節、Activity 的邊際貢獻
Bootstrap	按 origin / 月份重抽樣，重算 RMSE 差	估計改善區間與勝率
Guardrail	限制單一據點不可大幅惡化	避免整體平均掩蓋局部傷害

Bootstrap 欄位

輸出	解讀
Median RMSE change %	相對 baseline 的中位數變化；負值通常代表改善
95% interval	重抽樣後改善幅度的可能範圍；跨 0 代表方向不確定
P(beats baseline)	候選模型 RMSE 低於 baseline 的重抽樣比例

本專案採用的決策門檻

層級	門檻	用途
業務顯著	RMSE 改善約 $\geq 3\%$	避免為極小差距增加維護成本
Challenger	P(勝過 baseline) $\geq 80\%$	可保留觀察，但不自動上線
Promote	P(勝過 baseline) $\geq 95\%$	需同時通過其他 guardrails
Branch guardrail	任一據點惡化不宜 $> 5\%$	避免犧牲局部據點換整體平均

這些是本專案的治理門檻，不是所有企業都通用的自然定律。若錯誤成本、樣本量或營運容忍度改變，門檻也應重新定義。

Champion / Challenger / Fallback

Champion 是目前正式方案；**Challenger** 有潛力但證據尚未完整；**Fallback** 是資料不足或模型失敗時仍能穩定產出的安全方案。三者是不同角色，不應混為一談。

09 V2.2 正式 Feature Router

不同據點、不同 horizon 使用不同合法特徵集合。

據點	h	Feature route	特徵數	理由
A52 / A54 / A55	h=1 ~ 4	Recursive Core	約 13	近中期核心遞迴特徵
A52 / A54 / A55	h=5 ~ 6	V2 Safe Compact	依 h 過濾，約 21	較遠期保留合法、安全特徵
A53	h=1 ~ 6	Core guardrail	核心集合	實驗未證明切換可穩定改善
A56	h=1 ~ 6	Core fallback	可用核心	新據點，小樣本優先不中斷
V3 Activity	h=1	Lab Challenger	活動摘要群	尚未達正式升級證據

A56 為什麼特殊？

A56 成立時間較晚，可形成完整特徵的訓練列曾只有 9 筆。若沿用其他據點的最低 24 列規則，正式預測與多期回測都會失敗。因此 V2.2 將「資料不足」視為預期狀態，而不是程式異常：

- 正式預測允許在至少 9 筆完整列時使用 Core fallback。
- 不勉強產生缺乏歷史基礎的 24 個月 XGB 多期回測。
- Hybrid 誤差尺度不足時退回據點層級或更保守的 fallback。
- 輸出中保留 xgb_feature_version、xgb_feature_n、weight_source 等治理欄位。

成熟系統的判斷

Error 原本可能是為了阻止小樣本模型被誤用；問題不是該不該移除 Error，而是把『硬停止』改成『有條件、可追溯、保守的 fallback』。

目前的正式與研究邊界

狀態	內容
正式	V2.2 route、固定 XGB 參數、200 rounds、Hybrid fallback
已驗證但不升級	完整 V3、部分高頻摘要、曾受洩漏影響的調參結果
下一步研究	獨立 Hybrid 權重、區間 coverage、服務案件 pipeline nowcast、drift monitoring

10 如何閱讀每次跑完的輸出

先查結構與合法性，再查分數，最後才談升級。

物件	重要欄位	主要問題
xgb_forecast	據點、年月、h、pred、xgb_feature_version、xgb_feature_n	路由是否如預期；A56 是否 fallback
bt_eval_h / bt_eval_branch	RMSE、MAE、MAPE、n	模型分據點 / h 的表現
bt_weights_h / bt_weights_branch	inv_rmse、weight	Hybrid 權重是否合理、總和是否為 1
hybrid_input	三模型 pred、weight_final、weight_source	是否缺模型、重複或 fallback
hybrid_auto	Hybrid pred、lower95、upper95、hybrid_rmse	最終預測與不確定性
benchmark_winner_common	共同樣本上的 winner	Hybrid 是否真的勝過簡單模型
feature lab results	RMSE change、bootstrap CI、勝率、branch guardrail	候選特徵能否升級

建議判讀順序

步驟	檢查層	判斷
1	資料完整	排除當月部分月；檢查日期、據點、Actual 與缺失
2	特徵合法	確認 route、h-aware availability 與 leakage blacklist
3	回測公平	Walk-forward、common keys、同一 Actual、沒有 duplicated model
4	模型分數	RMSE 主、MAE / MAPE / WAPE / Bias 輔、n 必看
5	穩定性	跨據點、跨 h、最差月份、bootstrap 與 guardrail
6	Hybrid	三模型齊全、權重和 1、weight source、區間誤差樣本
7	營運輸出	是否可解釋、可重跑、失敗時能 fallback、有人可交接

常見誤解

誤解	正確理解
Feature 越多越強	更多特徵會增加變異、洩漏風險與維護成本
Gain 高就該保留	Gain 不保證預測時可取得，也不保證外層回測改善
test RMSE 低就完成	仍可能是切分、選擇或權重洩漏
Hybrid 一定勝單模	高度相關的錯誤或不當權重會讓 Hybrid 更差
MAPE 可直接比所有據點	低 Actual 據點會被比例誤差放大
Error 代表程式寫壞	也可能是完整性 guardrail 正確阻止不合法結果
調參是最重要的一步	合法特徵、驗證設計與資料品質通常影響更大

速查 一頁複習卡

看到輸出時，先用這一頁定位問題。

名詞	一句話意義	判讀重點
RMSE	大錯誤懲罰較重；主要 ranking	越低越好，但要同樣本
MAE	平均絕對差；典型誤差	與 RMSE 差距大 = 可能有尖峰
MAPE	相對百分比誤差	Actual 低時慎用
WAPE	總量加權相對誤差	適合彙總，不代表每月公平
Bias	平均高估 / 低估	正 = 高估，負 = 低估
n	有效樣本數	小 n 不輕易下結論
eta	每輪學習速度	小 = 穩但需更多 rounds
max_depth	樹的交互作用深度	深 = 彈性高也較易過擬合
min_child_weight	葉節點最低證據量	大 = 保守
subsample	列抽樣比例	降低變異
colsample_bytree	特徵抽樣比例	降低特徵依賴
nrounds	Boosting 輪數	配合 eta / early stopping
Gain	特徵帶來的損失下降	不是因果，也不是上線許可
h	預測提前期	h 越遠，合法特徵越少
Recursive	預測寫回再推下一期	會累積誤差
Common-key	所有模型共用評估列	保證公平比較
RFE	折內遞迴選特徵	避免 selection leakage
Ablation	加 / 減群組看邊際貢獻	回答某類特徵是否真的有用
Bootstrap	重抽樣估計改善不確定性	看 CI 與勝率，不只點估計
Fallback	資料不足時的保守路徑	不中斷且可追溯

可上線判斷式

可信結果 = 合法資料 × 時序驗證 × 公平樣本 × 穩定改善 × 可追溯 fallback
任何一項為 0，漂亮的 RMSE 都不能單獨證明模型可信。

附錄 A 模型治理與下一步

把個人研究成果變成可維護的企業資產。

優先	工作	完成定義
P0	保存每次 run manifest	資料截止月、script 版本、feature route、參數、seed、套件版本
P0	建立輸入 / 輸出 schema check	欄位、型別、key 唯一性、模型數、權重和
P1	Nested Hybrid weights	外層月份只使用更早回測誤差估權重
P1	區間 calibration	按據點 / h 追蹤 80% / 95% coverage 與 width
P1	Drift monitoring	特徵分布、殘差、Bias、winner 變化與 A56 樣本成長
P2	服務案件 nowcast Challenger	用入廠日、免費 / 一般維修、未結案件存量預測近月
P2	正式 Champion / Challenger 流程	預先定義觀察期、門檻、rollback 與升級紀錄

建議交接包

- 正式 production script 與不直接改正式模型的 feature lab。
- 資料欄位字典、特徵可取得性矩陣與 leakage blacklist。
- 每次回測結果、common-key QA、參數與 route manifest。
- 一鍵重跑說明、失敗訊息解讀、A56 fallback 決策。
- 業務端使用說明：點預測、區間、目標差距與不可承諾事項。

進一步研究問題

- Hybrid 的改善在完全獨立權重下是否仍成立？
- 哪些最差月份可由案件 pipeline、入廠日至結帳延遲解釋？
- Volatility / Entropy 是否更適合預測誤差尺度與 regime，而不是點預測？
- A56 累積到多少完整月份後，才應解除 fallback 並納入正式多期回測？
- 各據點分別建模的收益，是否足以抵銷維護五套模型的成本？

最重要的治理原則

不要把『曾經跑贏』當成永久有效。模型要保存版本、持續回測、監控漂移，並允許簡單模型重新成為 Champion。

附錄 B 公式、設定與詞彙

公式總表

項目	公式
Error	$e_i = \text{Pred}_i - \text{Actual}_i$
RMSE	$\sqrt{[(1/n) \sum (\text{Pred}_i - \text{Actual}_i)^2]}$
MAE	$(1/n) \sum \text{Pred}_i - \text{Actual}_i $
MAPE	$(100/n) \sum (\text{Pred}_i - \text{Actual}_i) / \text{Actual}_i $
WAPE	$100 \times \sum \text{Pred}_i - \text{Actual}_i / \sum \text{Actual}_i $
Bias	$(1/n) \sum (\text{Pred}_i - \text{Actual}_i)$
Inverse-RMSE weight	$(1/\text{RMSE}_m) / \sum_j (1/\text{RMSE}_j)$
Hybrid prediction	$\sum_m \text{weight}_m \times \text{Pred}_m$
Approx. 95% interval	$\text{Pred} \pm 1.96 \times \text{Hybrid RMSE}$; lower bound 不低於 0

正式 XGB 基準設定

objective = reg:squarederror | eval_metric = rmse | eta = 0.05 | max_depth = 4 | min_child_weight = 3 | subsample = 0.8 | colsample_bytree = 0.8 | nrounds = 200 | seed = 20260717

詞彙補充

詞彙	意義
Actual	實際觀測收入
Pred	模型產生的點預測
Origin	當次預測可使用資料的最後時間點
Fold	一次訓練 / 驗證切分
Regime	資料生成型態不同的狀態，例如高波動期
Calibration	預測區間的標稱機率是否符合實際覆蓋率
Drift	輸入特徵、關係或誤差分布隨時間改變
Nowcast	利用當期已發生的即時訊號估計尚未結束期間
Guardrail	即使平均改善也不可違反的安全條件
Reproducibility	相同資料、版本與設定可以重建相同結果

來源與版本說明：本手冊依 Warranty Revenue Forecasting System 2.2、Feature Selection Lab 的 Phase 1~5b 實驗、Production Integration 設計與 2026-07 對話中的治理決策整理。本文件用於學習與交接；正式決策仍應以最新程式、資料與回測輸出為準。

END OF HANDBOOK